SQL - Funkcje okna (Window functions)
Lab 1

Imiona i nazwiska: Jan Małek

Celem ćwiczenia jest przygotowanie środowiska pracy, wstępne zapoznanie się z działaniem funkcji okna (window functions) w SQL, analiza wydajności zapytań i porównanie z rozwiązaniami przy wykorzystaniu "tradycyjnych" konstrukcji SQL

Swoje odpowiedzi wpisuj w miejsca oznaczone jako:

> Wyniki:

```
-- ...
```

Ważne/wymagane są komentarze.

Zamieść kod rozwiązania oraz zrzuty ekranu pokazujące wyniki, (dołącz kod rozwiązania w formie tekstowej/źródłowej)

Zwróć uwagę na formatowanie kodu

Oprogramowanie - co jest potrzebne?

Do wykonania ćwiczenia potrzebne jest następujące oprogramowanie:

- MS SQL Server - wersja 2019, 2022, 2025
- PostgreSQL - wersja 15/16/17/18
- SQLite
- Narzędzia do komunikacji z bazą danych
    - SSMS - Microsoft SQL Managment Studio
    - DtataGrip lub DBeaver
- Przykładowa baza Northwind
    - W wersji dla każdego z wymienionych serwerów

Oprogramowanie dostępne jest na przygotowanej maszynie wirtualnej

Dokumentacja/Literatura

- Kathi Kellenberger, Clayton Groom, Ed Pollack, Expert T-SQL Window Functions in SQL Server 2019, Apres 2019

- Itzik Ben-Gan, T-SQL Window Functions: For Data Analysis and Beyond, Microsoft 2020

- Kilka linków do materiałów które mogą być pomocne - https://learn.microsoft.com/en-us/sql/t-sql/queries/select-over-clause-transact-sql?view=sql-server-ver16
    - https://www.sqlservertutorial.net/sql-server-window-functions/
    - https://www.sqlshack.com/use-window-functions-sql-server/
    - https://www.postgresql.org/docs/current/tutorial-window.html
    - https://www.postgresqltutorial.com/postgresql-window-function/
    - https://www.sqlite.org/windowfunctions.html
    - https://www.sqlitetutorial.net/sqlite-window-functions/
- W razie potrzeby - opis Ikonek używanych w graficznej prezentacji planu zapytania w SSMS jest tutaj:
    - https://docs.microsoft.com/en-us/sql/relational-databases/showplan-logical-and-physical-operators-reference

Przygotowanie

Uruchom SSMS - Skonfiguruj połączenie z bazą Northwind na lokalnym serwerze MS SQL

Uruchom DataGrip (lub Dbeaver)

- Skonfiguruj połączenia z bazą Northwind3
    - na lokalnym serwerze MS SQL
    - na lokalnym serwerze PostgreSQL
    - z lokalną bazą SQLite

Zadanie 1 - obserwacja

Wykonaj i porównaj wyniki następujących poleceń.

```
select avg(unitprice) avgprice
from products p;

select avg(unitprice) over () as avgprice
from products p;

select categoryid, avg(unitprice) avgprice
from products p
group by categoryid

select avg(unitprice) over (partition by categoryid) as avgprice
from products p;
```

Jaka jest są podobieństwa, jakie różnice pomiędzy grupowaniem danych a działaniem funkcji okna?

> Wyniki:

```
Podobieństwa: Zarówno klauzula GROUP BY, jak i funkcje okna (OVER)
pozwalają na wykonywanie funkcji agregujących, takich jak AVG(), na
określonym zbiorze danych.

Różnice: Tradycyjne grupowanie (GROUP BY categoryid) agreguje wiersze,
zwracając tylko jeden wiersz dla każdej unikalnej kategorii. Utracisz
dostęp do detali pojedynczych produktów w tym samym zapytaniu.

Funkcja okna z OVER (PARTITION BY categoryid) oblicza średnią dla każdej
kategorii, ale nie redukuje liczby wierszy w wyniku. Wynik agregacji jest
dołączany jako nowa kolumna do każdego oryginalnego wiersza w tabeli
products. Zapytanie z samym OVER() oblicza średnią dla całej tabeli i
dołącza ją do każdego wiersza.
```

Zadanie 2 - obserwacja

Wykonaj i porównaj wyniki następujących poleceń.

```
--1)

select p.productid, p.ProductName, p.unitprice,
       (select avg(unitprice) from products) as avgprice
from products p
where productid < 10

--2)
select p.productid, p.ProductName, p.unitprice,
       avg(unitprice) over () as avgprice
from products p
where productid < 10
```

Jaka jest różnica? Czego dotyczy warunek w każdym z przypadków? Napisz polecenie równoważne

- 1. z wykorzystaniem funkcji okna. Napisz polecenie równoważne
- 2. z wykorzystaniem podzapytania

> Wyniki:

```
W zapytaniu z funkcją okna funkcja agregująca avg(unitprice) over () jest
obliczana po przefiltrowaniu danych przez klauzulę WHERE. Zatem oblicza
ona średnią cenę tylko dla produktów, które spełniają warunek productid <
10.

W zapytaniu z podzapytaniem warunek WHERE productid < 10 filtruje tylko
zewnętrzny wynik. Podzapytanie (select avg(unitprice) from products)
```

```
oblicza średnią ze wszystkich produktów w bazie, niezależnie od warunku w
głównym zapytaniu.

1)
WITH CTE AS (
    SELECT p.productid, p.ProductName, p.unitprice,
           avg(unitprice) over () as avgprice
    FROM products p
)
SELECT * FROM CTE WHERE productid < 10;

2)
SELECT p.productid, p.ProductName, p.unitprice,
       (SELECT avg(unitprice) FROM products WHERE productid < 10) as
avgprice
FROM products p
WHERE productid < 10;
```

Zadanie 3

Baza: Northwind, tabela: products

Napisz polecenie, które zwraca: id produktu, nazwę produktu, cenę produktu, średnią cenę wszystkich produktów.

Napisz polecenie z wykorzystaniem z wykorzystaniem podzapytania, join'a oraz funkcji okna. Porównaj czasy oraz plany wykonania zapytań.

Przetestuj działanie w różnych SZBD (MS SQL Server, PostgreSql, SQLite)

W SSMS włącz dwie opcje: Include Actual Execution Plan oraz Include Live Query Statistics

w:700

W DataGrip użyj opcji Explain Plan/Explain Analyze

w:700

w:700

> Wyniki:

```
MS SQL
1. 77 rows retrieved starting from 1 in 367 ms (execution: 12 ms,
fetching: 355 ms). Koszt 0.0041.
Plan:
```

1. 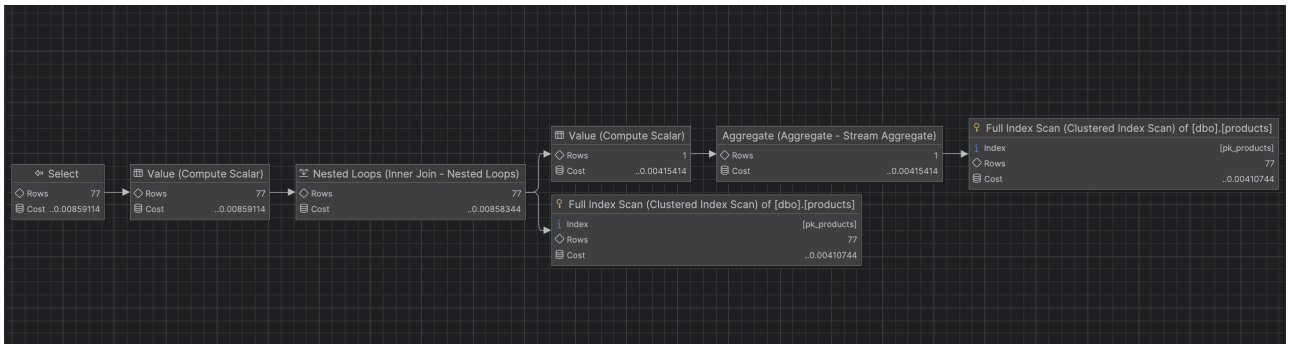


```
2. 77 rows retrieved starting from 1 in 384 ms (execution: 13 ms,
fetching: 371 ms). Koszt 0.0041.
Plan:
```

2.


```
3. 77 rows retrieved starting from 1 in 354 ms (execution: 13 ms,
fetching: 341 ms). Koszt 0.0041.
Plan:
```

3. 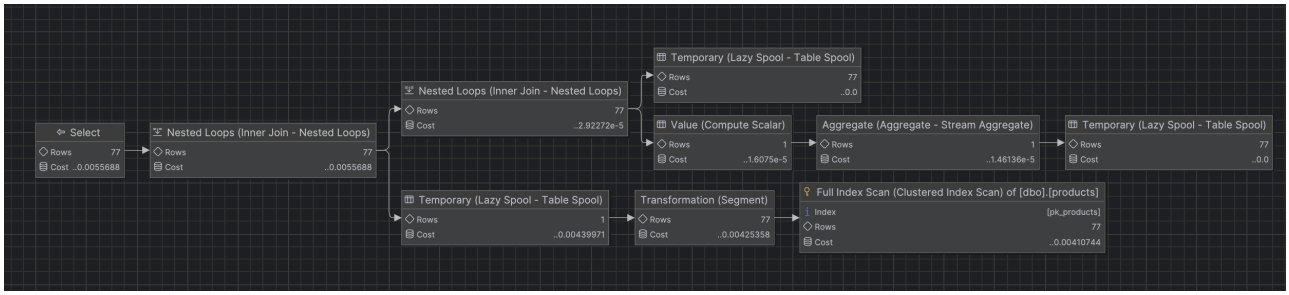


```
Postgres
1. 77 rows retrieved starting from 1 in 386 ms (execution: 16 ms,
fetching: 370 ms)
Plan:
```

1. 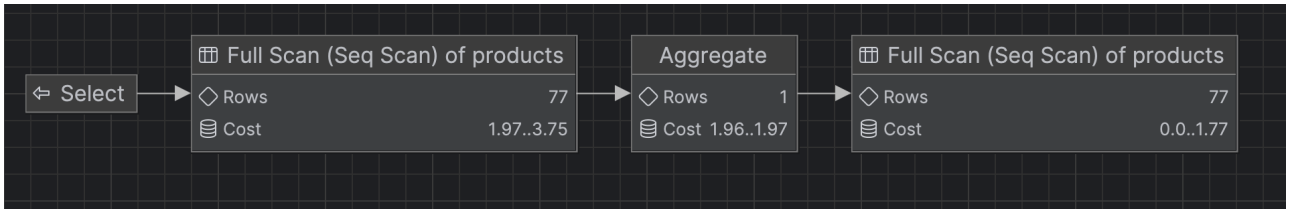

```
2. 77 rows retrieved starting from 1 in 343 ms (execution: 5 ms, fetching:
338 ms)
Plan:
```

2. 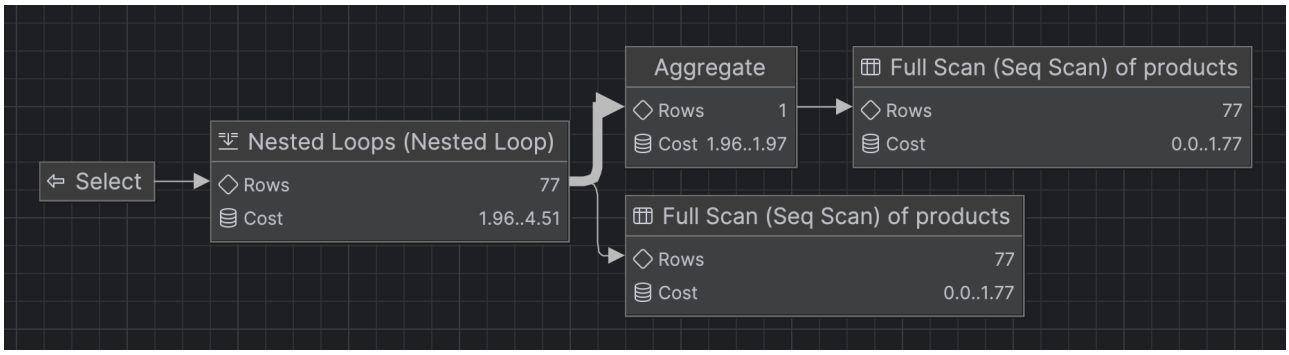


```
3. 77 rows retrieved starting from 1 in 339 ms (execution: 6 ms, fetching:
333 ms)
Plan:
```

3. 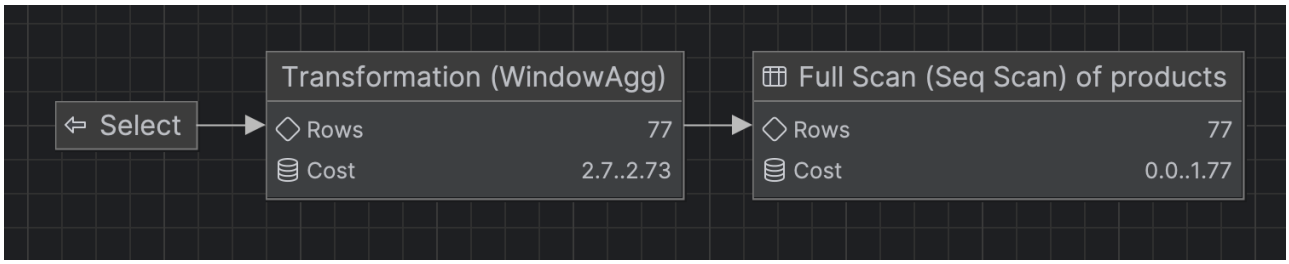


```
SQLite
1. 77 rows retrieved starting from 1 in 414 ms (execution: 17 ms,
fetching: 397 ms).
Plan:
```

1. 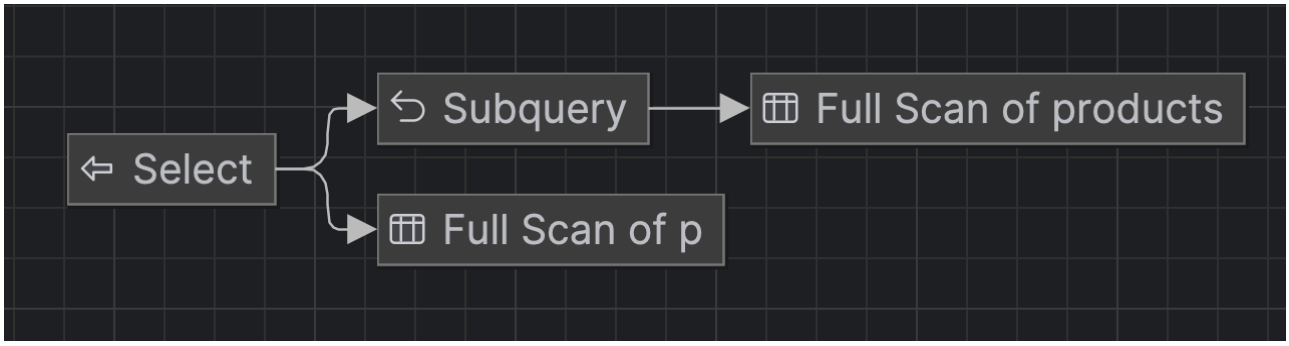


```
2. 77 rows retrieved starting from 1 in 372 ms (execution: 5 ms, fetching:
367 ms)
```

2. 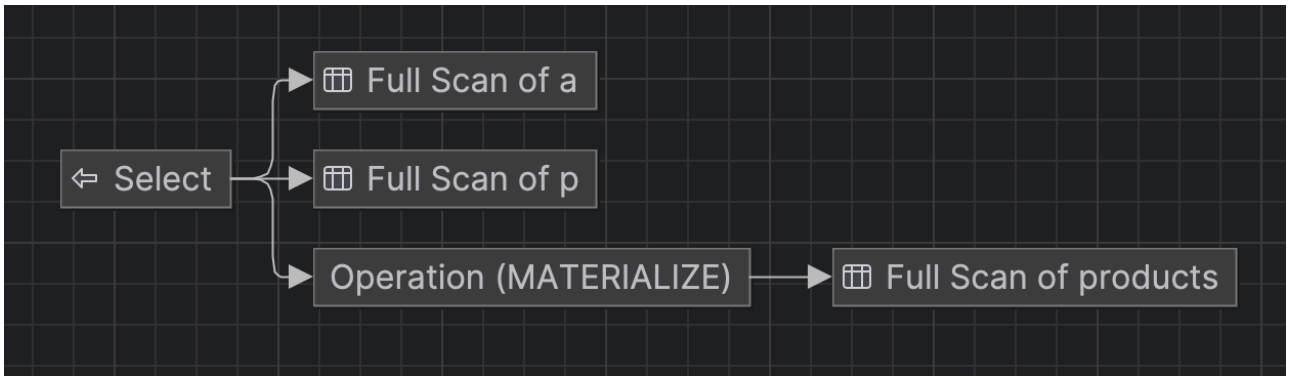


```
3. 77 rows retrieved starting from 1 in 358 ms (execution: 5 ms, fetching:
353 ms)
```

3. 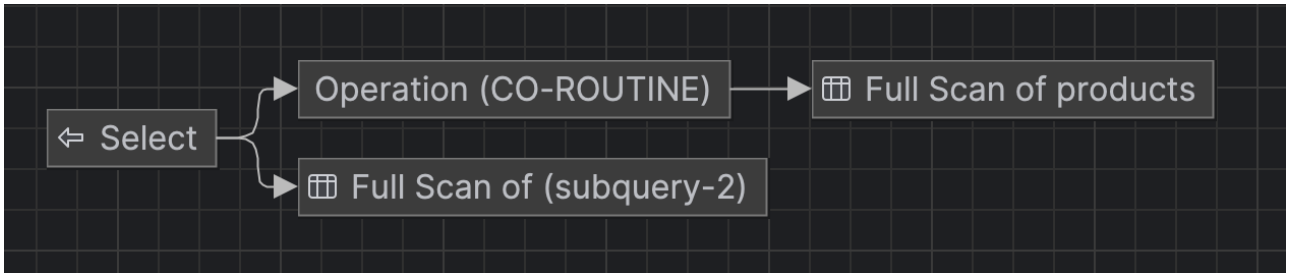


```
Analizując wyniki zapytań z Zadania 3 , można zauważyć interesujące
różnice w sposobie optymalizacji kodu przez poszczególne systemy
zarządzania bazami danych. Pod względem składni, polecenie wykorzystujące
funkcję okna z klauzulą OVER jest zdecydowanie najkrótsze i najbardziej
czytelne w porównaniu do konstrukcji z podzapytaniem czy złączeniem
(JOIN). Porównując czasy oraz plany wykonania zapytań, optymalizator w MS
SQL Server poradził sobie równie dobrze z każdym z trzech wariantów —
wszystkie wygenerowały identyczny koszt całkowity (0.0041) oraz bardzo
zbliżony czas samej egzekucji na poziomie 12–13 ms. Oznacza to, że silnik
MS SQL skutecznie zoptymalizował podzapytanie, najprawdopodobniej
wykonując agregację tylko raz. Sytuacja wygląda inaczej w przypadku
PostgreSQL i SQLite, gdzie wyraźnie zarysowały się różnice wydajnościowe.
W tych silnikach zapytanie oparte na podzapytaniu w klauzuli SELECT
okazało się najwolniejsze (odpowiednio 16 ms i 17 ms czasu egzekucji),
natomiast zastosowanie JOIN-a lub funkcji okna drastycznie poprawiło
wynik, skracając czas wykonania do zaledwie 5–6 ms. Podsumowując, chociaż
bardzo zaawansowane silniki potrafią zniwelować różnice wydajnościowe
wynikające ze sposobu zapisu, stosowanie funkcji okna pozostaje najlepszą
i najbezpieczniejszą praktyką, która gwarantuje optymalny czas wykonania
niezależnie od używanego środowiska.
```

Zadanie 4

Baza: Northwind, tabela products

Napisz polecenie, które zwraca: id produktu, nazwę produktu, cenę produktu, średnią cenę produktów w kategorii, do której należy dany produkt. Wyświetl tylko pozycje (produkty) których cena jest większa niż średnia cena.

Napisz polecenie z wykorzystaniem podzapytania, join'a oraz funkcji okna. Porównaj zapytania. Porównaj czasy oraz plany wykonania zapytań.

Przetestuj działanie w różnych SZBD (MS SQL Server, PostgreSql, SQLite)

> Wyniki:

```
SQL
1. 27 rows retrieved starting from 1 in 368 ms (execution: 27 ms,
fetching: 341 ms)
Plan:
```

1. 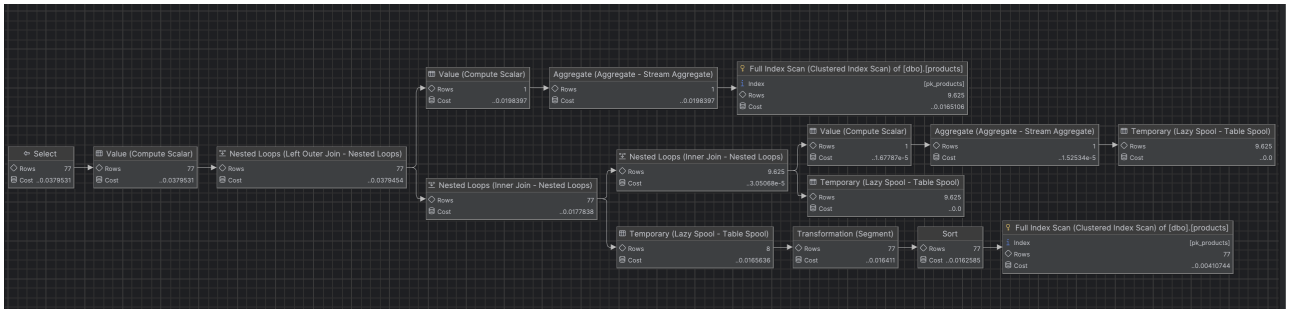


```
2. 27 rows retrieved starting from 1 in 349 ms (execution: 15 ms,
fetching: 334 ms)
Plan:
```

2. 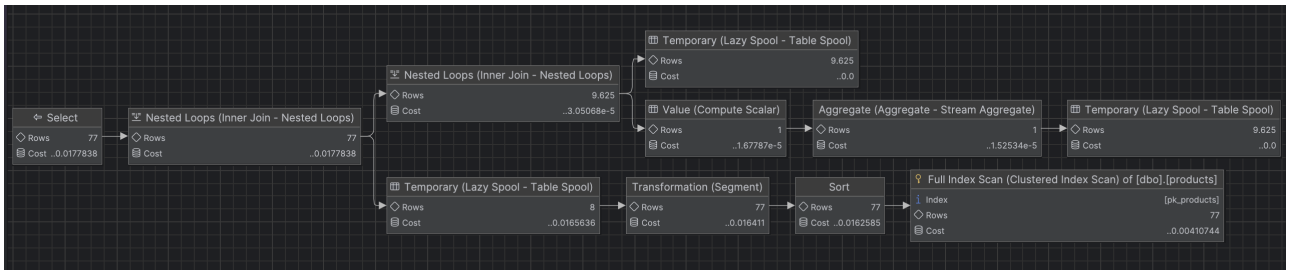


```
3. 27 rows retrieved starting from 1 in 350 ms (execution: 17 ms,
fetching: 333 ms)
Plan:
```

3. 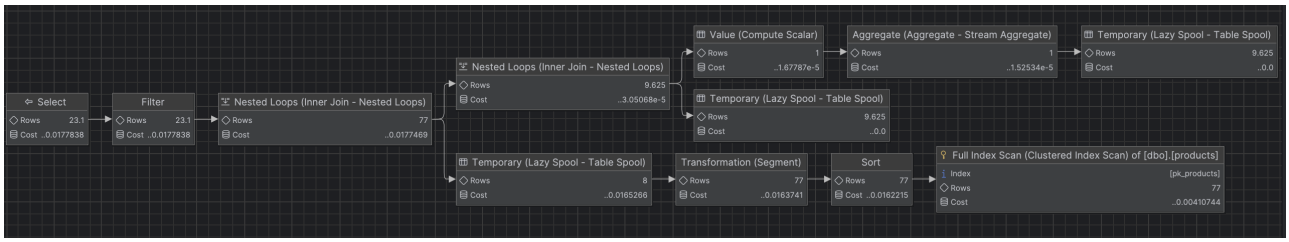


```
Postgres
1. 27 rows retrieved starting from 1 in 343 ms (execution: 7 ms, fetching:
336 ms)
Plan:
```

1. 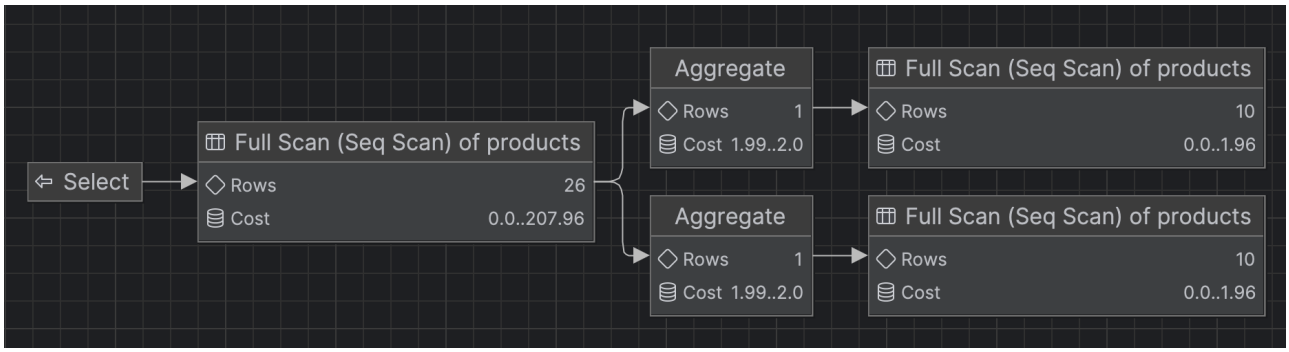


```
2. 27 rows retrieved starting from 1 in 338 ms (execution: 6 ms, fetching:
332 ms)
Plan:
```

2. 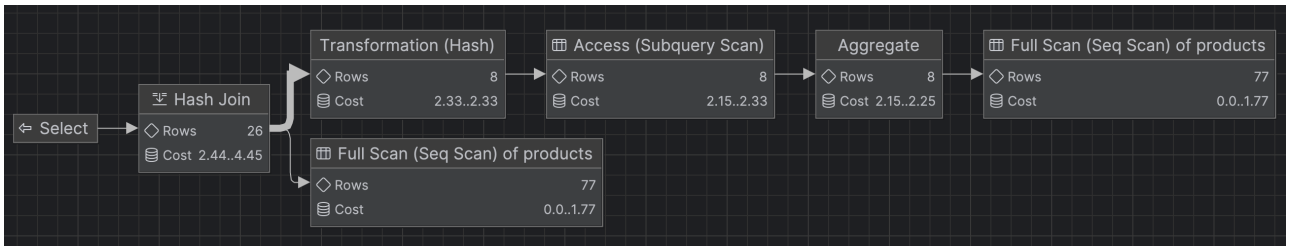


```
3. 27 rows retrieved starting from 1 in 340 ms (execution: 7 ms, fetching:
333 ms)
Plan:
```

3. 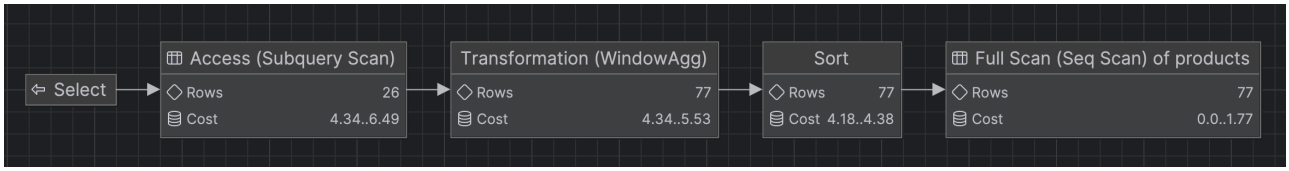


```
SQLite
1. 27 rows retrieved starting from 1 in 360 ms (execution: 5 ms, fetching:
```

```
355 ms)
Plan:
```

1. 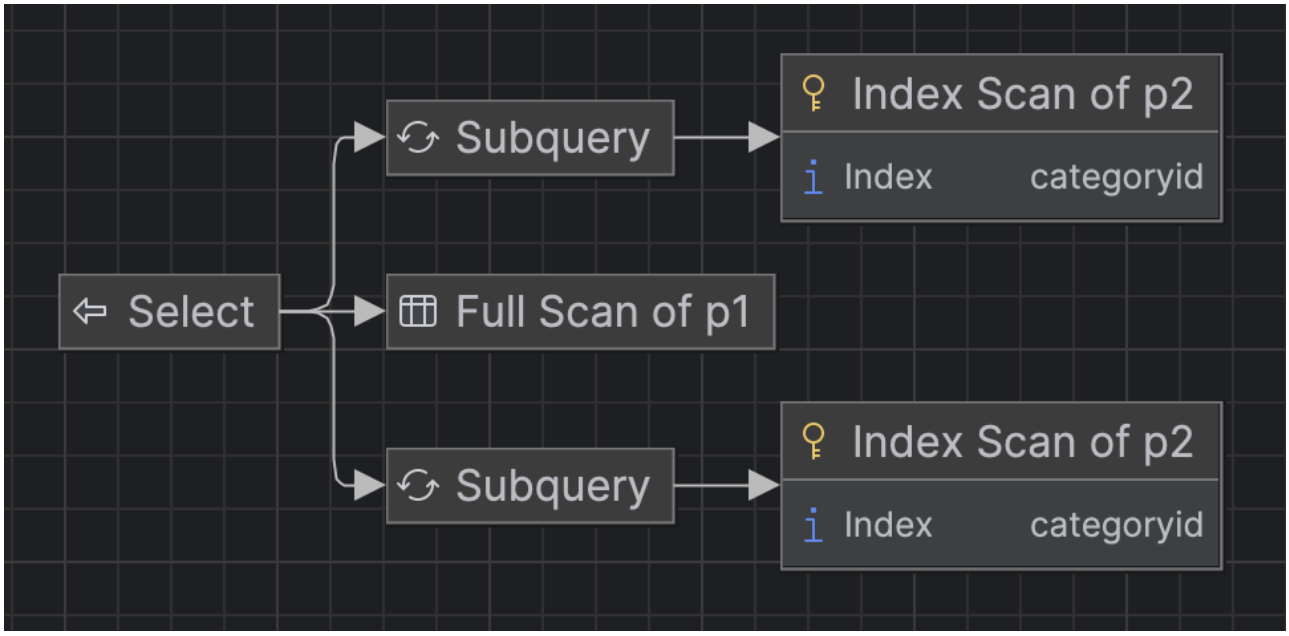


```
2. 27 rows retrieved starting from 1 in 356 ms (execution: 4 ms, fetching:
352 ms)
```

2. 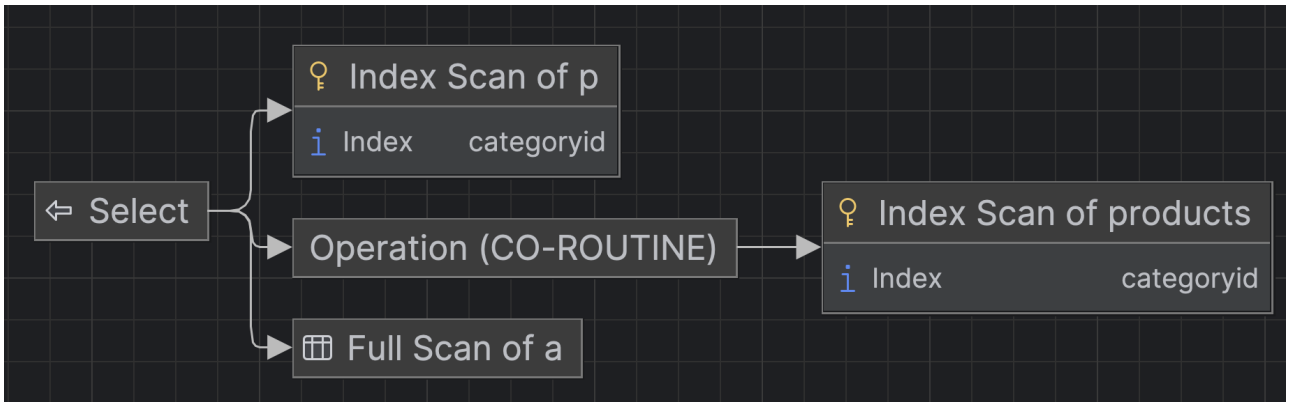


```
3. 27 rows retrieved starting from 1 in 323 ms (execution: 4 ms, fetching:
319 ms)
```

3. 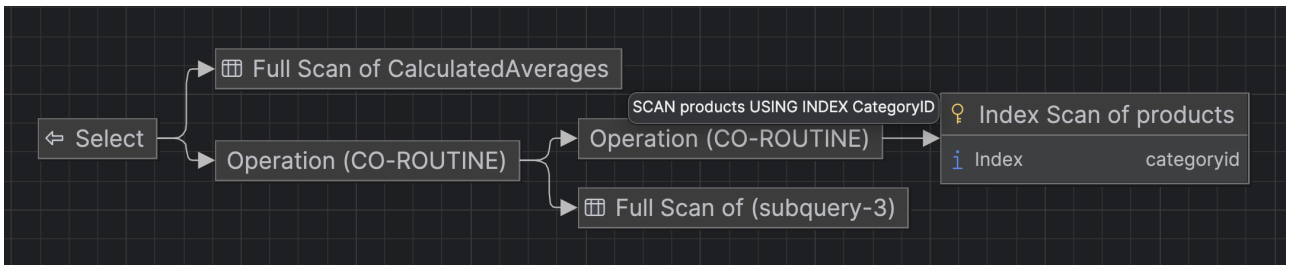

```
Analizując wyniki zapytań z Zadania 4, w którym konieczne było obliczenie
średniej ceny produktów w danej kategorii i odfiltrowanie tych droższych
niż średnia, można zauważyć wyraźniejsze różnice w wydajności w zależności
od wybranej metody, co jest szczególnie widoczne w środowisku MS SQL
Server. W tym silniku użycie skorelowanego podzapytania okazało się
najmniej optymalne, generując czas egzekucji na poziomie 27 ms, co wynika
z faktu, że baza musi przeliczać warunki wielokrotnie dla każdego wiersza.
Zastosowanie złączenia (JOIN) oraz funkcji okna z partycjonowaniem
znacząco poprawiło ten wynik, redukując czas wykonania do odpowiednio 15
ms i 17 ms. Z kolei systemy PostgreSQL oraz SQLite wykazały się bardzo
agresywną optymalizacją, obsługując wszystkie trzy warianty zapytań w
niemal identycznym, niezwykle krótkim czasie (od 4 do 7 ms), co sugeruje,
że ich optymalizatory pod spodem przekształciły skorelowane podzapytanie
do postaci wydajniejszego złączenia. Podsumowując, chociaż nowoczesne i
lekkie silniki potrafią sprawnie zoptymalizować każdy kod, korzystanie z
funkcji okna (lub złączeń) zamiast skorelowanych podzapytań jest praktyką
znacznie bezpieczniejszą, która zapobiega spadkom wydajności w bardziej
rygorystycznych środowiskach korporacyjnych takich jak MS SQL, zachowując
przy tym wysoką czytelność logiki analitycznej.
```

Zadanie 5

Oryginalna baza Northwind jest bardzo mała. Warto zaobserwować działanie na nieco większym zbiorze danych.

Baza Northwind3 zawiera dodatkową tabelę product_history

- 2,2 mln wierszy

Bazę Northwind3 można pobrać z moodle (zakładka - Backupy baz danych)

Wykonaj polecenia: `select count(*) from product_history`, potwierdzające wykonanie zadania

Wyniki:

	count
1	2310000

Zadanie 6

Baza: Northwind, tabela product_history

Napisz polecenie, które zwraca: id pozycji, id produktu, nazwę produktu, id_kategorii, cenę produktu, średnią cenę produktów w kategorii do której należy dany produkt. Wyświetl tylko pozycje (produkty)

których cena jest większa niż średnia cena.

W przypadku długiego czasu wykonania ogranicz zbiór wynikowy do kilkuset/kilku tysięcy wierszy

pomocna może być konstrukcja `with`

```
with t as (

....
)
select * from t
where id between ....
```

Napisz polecenie z wykorzystaniem podzapytania, join'a oraz funkcji okna. Porównaj zapytania. Porównaj czasy oraz plany wykonania zapytań.

Przetestuj działanie w różnych SZBD (MS SQL Server, PostgreSql, SQLite)

> Wyniki:

```
1)
WITH t AS (
    SELECT
        id,
        productid,
        productname,
        categoryid,
        unitprice,
        (SELECT AVG(unitprice) FROM product_history p2 WHERE p1.categoryid
= p2.categoryid) AS avgprice
    FROM product_history p1
)
SELECT * FROM t
WHERE id BETWEEN 1 AND 10000
  AND unitprice > avgprice;

2)
WITH t AS (
    SELECT
        p.id,
        p.productid,
        p.productname,
        p.categoryid,
        p.unitprice,
        a.avgprice
    FROM product_history p
    JOIN (
        SELECT categoryid, AVG(unitprice) AS avgprice
        FROM product_history
        GROUP BY categoryid
```

```sql
    ) a ON p.categoryid = a.categoryid
)
SELECT * FROM t
WHERE id BETWEEN 1 AND 10000
  AND unitprice > avgprice;

3)
WITH t AS (
    SELECT
        id,
        productid,
        productname,
        categoryid,
        unitprice,
        AVG(unitprice) OVER(PARTITION BY categoryid) AS avgprice
    FROM product_history
)
SELECT * FROM t
WHERE id BETWEEN 1 AND 10000
  AND unitprice > avgprice;
```

```
SQL
1. 500 rows retrieved starting from 1 in 394 ms (execution: 56 ms,
fetching: 338 ms)
Plan:
```

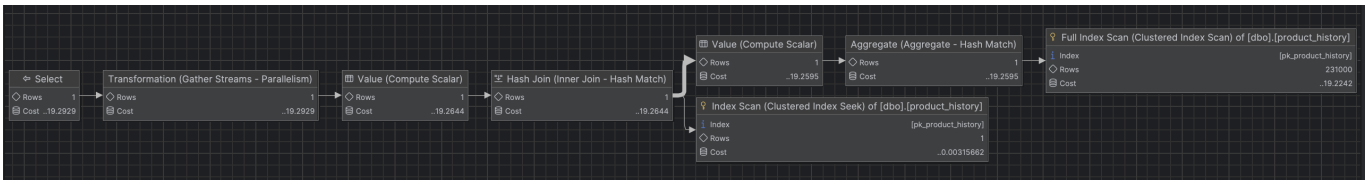


```
2. 500 rows retrieved starting from 1 in 431 ms (execution: 86 ms,
fetching: 345 ms)
Plan:
```

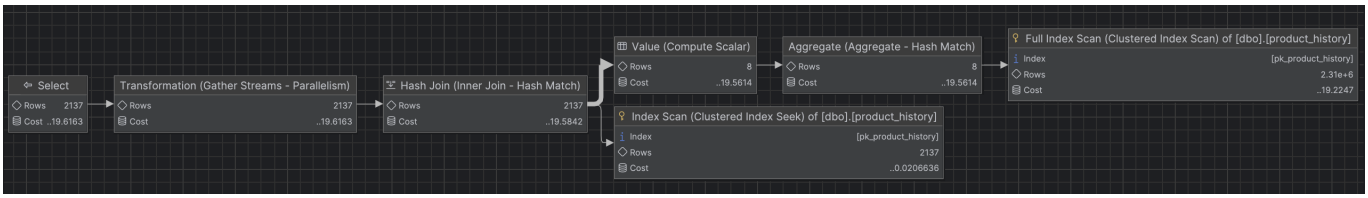


```
3. 500 rows retrieved starting from 1 in 606 ms (execution: 268 ms,
fetching: 338 ms)
Plan:
```

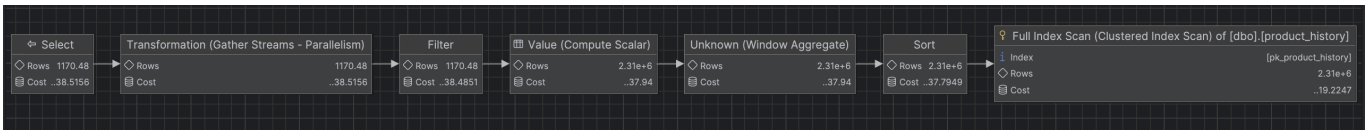


```
Postgres
1. 500 rows retrieved starting from 1 in 2 m 35 s 214 ms (execution: 2 m
34 s 847 ms, fetching: 367 ms)
Plan:
```

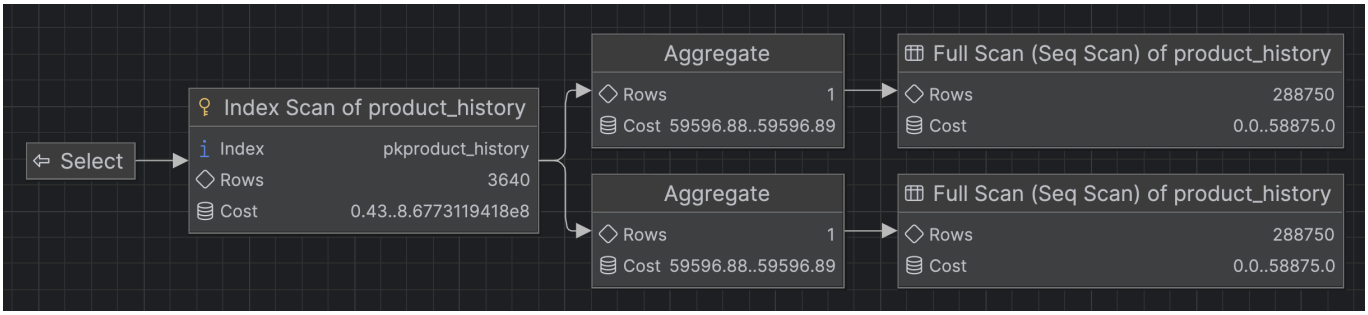


```
2. 500 rows retrieved starting from 1 in 615 ms (execution: 272 ms,
fetching: 343 ms)
Plan:
```

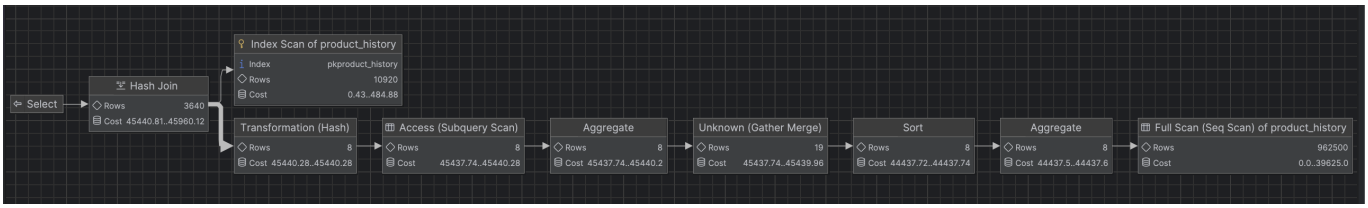


```
3. 500 rows retrieved starting from 1 in 1 s 165 ms (execution: 820 ms,
fetching: 345 ms)
Plan:
```

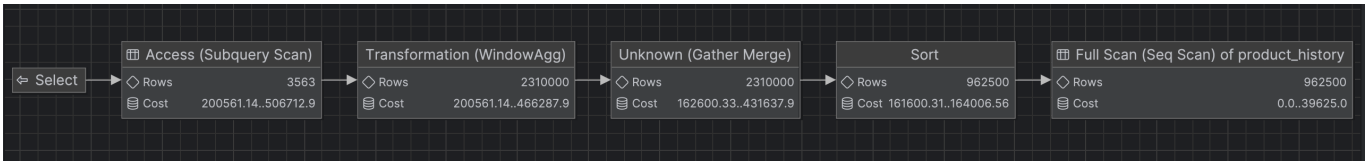


```
SQLite
1. 500 rows retrieved starting from 1 in 2 m 18 s 367 ms (execution: 996
ms, fetching: 2 m 17 s 371 ms)
Plan:
```

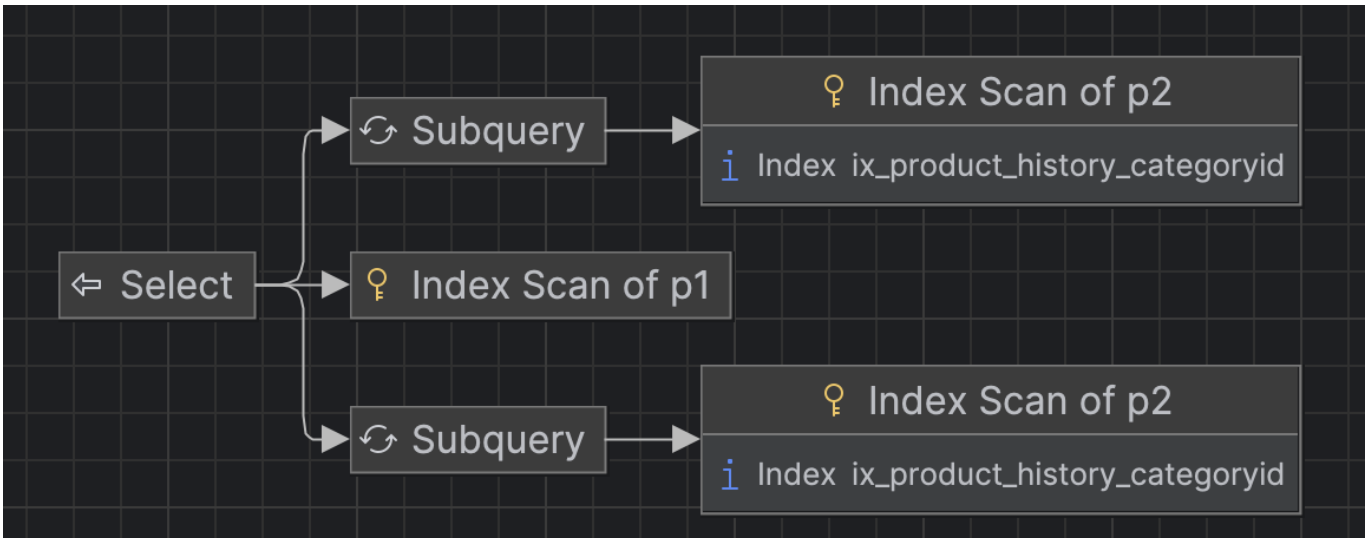


```
2. 500 rows retrieved starting from 1 in 441 ms (execution: 102 ms,
fetching: 339 ms)
Plan:
```

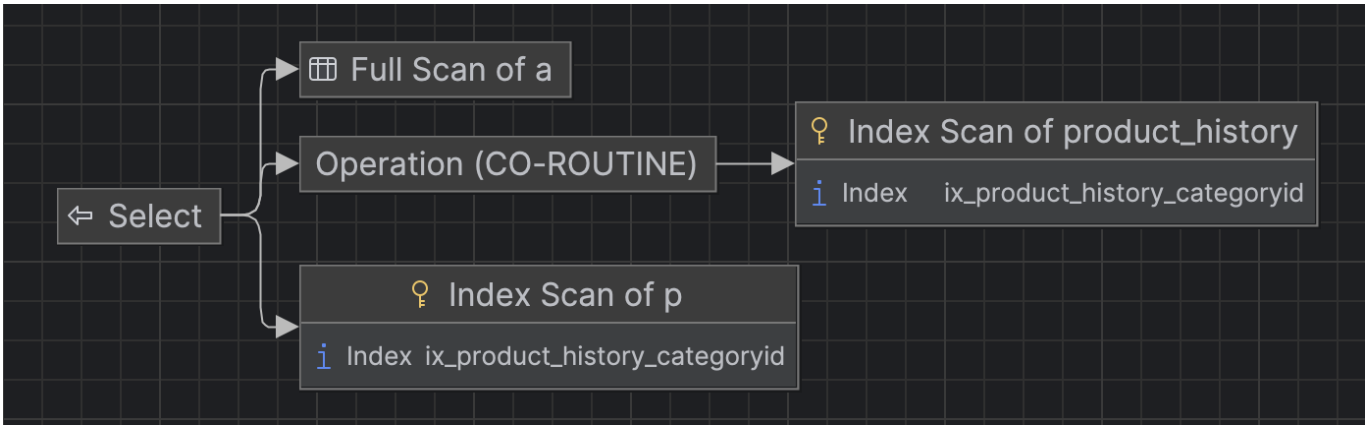


```
3. 500 rows retrieved starting from 1 in 569 ms (execution: 234 ms,
fetching: 335 ms)
Plan:
```

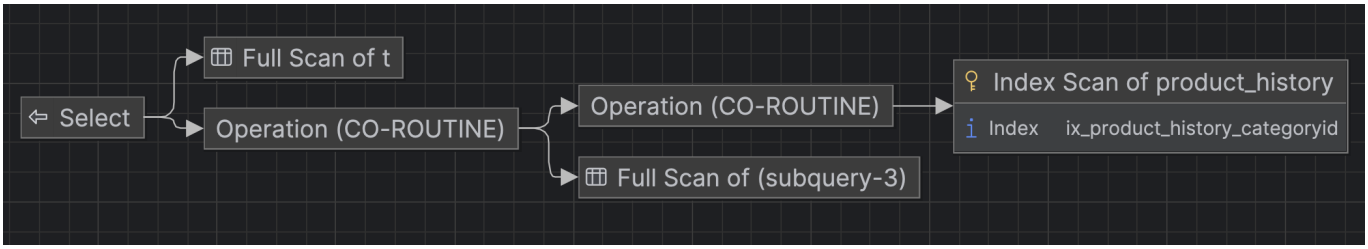


```
Analiza wyników na ponad dwumilionowym zbiorze danych obnaża ogromne
różnice w optymalizacji silników. Zastosowanie skorelowanego podzapytania
doprowadziło do całkowitego załamania wydajności w PostgreSQL i SQLite
(czasy egzekucji powyżej 2 minut), podczas gdy zaawansowany optymalizator
MS SQL Server poradził sobie z nim w zaledwie 56 ms. Najbardziej stabilnym
```

```
rozwiązaniem na wszystkich platformach okazało się złączenie (JOIN),
osiągając bardzo dobre i wyrównane czasy rzędu kilkuset milisekund.
Funkcja okna wypadła w tym specyficznym przypadku nieco gorzej od JOIN-a
(czasy od 234 ms do 820 ms), ponieważ wymusiła na silnikach wykonanie
kosztownego partycjonowania całego, dwumilionowego zbioru przed
ostatecznym odfiltrowaniem wyników na zewnątrz (WHERE id BETWEEN).
Podsumowując: przy dużych wolumenach danych należy bezwzględnie unikać
skorelowanych podzapytań na rzecz złączeń (JOIN), które gwarantują wysoką
i przewidywalną wydajność niezależnie od używanego systemu bazodanowego.
```

---

zadanie	pkt
1	1
2	1
3	1
4	1
5	1
6	2
razem:	7